第5章 数据库系统

枯燥的工程师

淘宝搜索：系统分析师 规格严考

章节概述

5.1 数据库管理系统
5.2 关系数据库
5.3 数据库控制功能
5.4 数据库设计与建模
5.5 分布式数据库
5.6 数据仓库技术
5.7 数据挖掘
5.8 非关系数据库

主要内容：数据库基础 、关系型数据库、分布式数据库、数据库控制、数据库设计等，相对好理解。
题型分布：选择 案例分析
考试分值：5—8分
学习方法：理解为主、适当记忆

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.1 数据库管理系统

概述

三级划分法

数据模型

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

概述

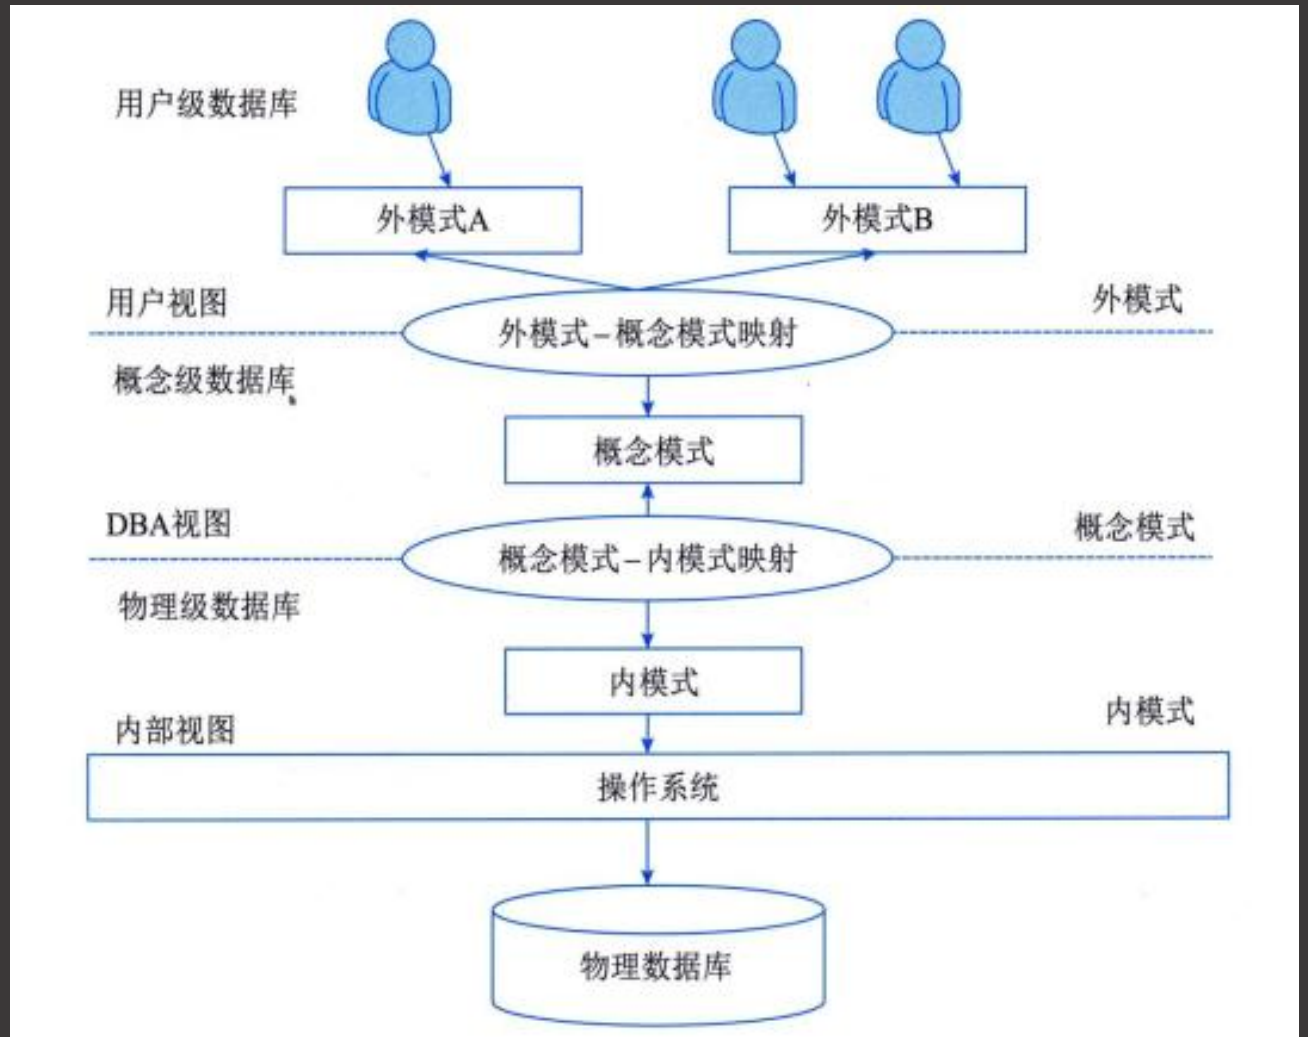
数据库是长期存储在计算机内的、有组织的、可共享的数据集合，数据库系统是指在计算机信息系统中引入数据库后的系统，一般由数据库、数据库管理系统（DBMS）、应用系统、数据库管理员（DBA）和用户构成。

数据库管理系统是一种操纵和管理数据库的大型软件，用于建立、使用和维护数据库。它对数据库进行统一的管理和控制，以保证数据库的安全性和完整性。用户通过DBMS访问数据库中的数据，数据库管理员也通过DBMS进行数据库的维护工作。DBMS可以支持多个应用程序和用户用不同的方法在同时或不同时刻去建立、修改和询问数据库。大部分DBMS提供数据定义语言（DDL）和数据操作语言（DML），供用户定义数据库的模式结构与权限约束，实现对数据的追加、删除等操作。

微信公众号：规格严考；bilibili：枯燥的工程师

三级划分法

数据库系统由外模式、概念模式和内模式三级构成。



淘宝搜索：系统分析师 规格严考

三级划分法

外模式也称为子模式或用户模式，对应于用户级数据库。外模式用以描述用户看到或使用的那部分数据的逻辑结构，是数据库用户的数据视图，是与某一应用有关的数据的逻辑表示。一个数据库可以有多个外模式，一个应用程序只能使用一个外模式。

概念模式也称为模式或逻辑模式，对应于概念级数据库。概念模式是数据库中全体数据的逻辑结构和特征的描述，是所有用户的公共数据视图，用以描述现实世界中的实体及其性质与联系，定义记录、数据项、数据的完整性约束条件及记录之间的联系。一个数据库只有一个概念模式。

内模式对应于物理级数据库，是数据物理结构和存储方式的描述，内模式定义的是存储记录的类型、存储域的表示和存储记录的物理顺序，以及索引和存储路径等数据的存储组织。一个数据库只有一个内模式。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

三级划分法

两级独立性

物理独立性是指用户的应用程序与存储在磁盘上的数据库中的数据是相互独立的，当数据的物理存储改变时，应用程序不需要改变。

逻辑独立性是指用户的应用程序与数据库中的逻辑结构是相互独立的，当数据的逻辑结构改变时，应用程序不需要改变。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

数据模型

数据模型所描述的内容包括3个部分，分别是数据结构、数据操作和数据约束。

主要的数据模型有层次模型、网状模型、关系模型和面向对象模型。

1. 层次模型

层次模型是最早出现的数据模型，由于它采用了树状结构作为数据的组织方式，整体结构也是分层状的，所以称其为层次模型。

2. 网状模型

网状模型用有向图表示实体类型和实体之间的联系。网状模型的优点是记录之间的联系通过指针实现，多对多的联系容易实现，查询效率高；其缺点是编写应用程序比较复杂，程序员必须熟悉数据库的逻辑结构。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

数据模型

3. 关系模型

关系模型用表格结构表达实体集，用外键表示实体之间的联系。关系模型是目前应用最广泛的一种数据模型，例如，Oracle、DB2、SQLServer、Sybase和MySQL等。

4. 面向对象模型

面向对象模型是用面向对象的观点来描述现实世界实体的逻辑组织、对象之间的限制和联系等的模型。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.2 关系数据库

关系的基本概念

关系模型

规范化理论

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

关系的基本概念

（1）属性。在现实世界中，要描述一个事物常常取若干特征来表示，这些特征称为属性。例如，学生用学号、姓名、性别、系别、年龄、籍贯等属性来描述。

（2）域。每个属性的取值范围所对应的值的集合，称为该属性的域。例如，学号的域是6位整型数，姓名的域是10位字符，性别的域为{男，女}等。

（3）目或度。二维表关系R（D，D，…D）中的R表示关系的名字，n是关系的目或度。

（4）候选码。若关系中的某一属性或属性组的值能唯一地标识一个元组则称该属性或属性组为候选码。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

关系的基本概念

（5）主码。或称主键，若一个关系有多个候选码，则选定其中一个为主码。

（6）主属性。包含在任何候选码中的属性称为主属性。不包含在任何候选码中的属性称为非主属性。

（7）外码。如果关系模式R中的属性或属性组非该关系的码，但它是其他关系的码，那么该属性集对关系模式R而言是外码。

（8）全码。关系模型的所有属性组是这个关系模式的候选码，称为全码。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

关系模型

关系代数的基本运算主要有并、差、交、笛卡儿积、投影、选择、连接和除。

（1）并。R∪S的元组包括R和S所有元组的集合。

（2）差。R-S的元组包括R中有而S中没有的元组的集合。

（3）交。R∩S的元组包括R和S相同元组的集合。

（4）笛卡儿积。R为有m元的关系，S为有n元的关系，则R×S是m+n元的元组的集合，其前m个元素来自R的一个元组，而后n个元素来自S的一个元组。

（5）投影。从一个关系中抽取指明的属性（列）。

（6）选择。从关系R中抽取出满足给定限制条件的记录。

微信公众号：规格严考；bilibili：枯燥的工程师

关系模型

$R \cup S$

A	B	C
a	b	c
b	a	d
c	d	e
d	f	g
f	h	k

$R - S$

A	B	C
a	b	c
c	d	e

$\pi_{A,C}(R)$

A		C
a		c
b		d
c		e
d		g

$\sigma_{A>B}(R)$

A	B	C
b	a	d

$R \times S$

R.A	R.B	R.C	S.A	S.B	S.C
a	b	c	b	a	d
a	b	c	d	f	g
a	b	c	f	h	k
b	a	d	b	a	d
b	a	d	d	f	g
b	a	d	f	h	k
c	d	e	b	a	d
c	d	e	d	f	g
c	d	e	f	h	k
d	f	g	b	a	d
d	f	g	d	f	g
d	f	g	f	h	k

$\sigma_{3<4}(R \times S)$

R.A	R.B	R.C	S.A	S.B	S.C
a	b	c	d	f	g
a	b	c	f	h	k
b	a	d	f	h	k
c	d	e	f	h	k

淘宝搜索：系统分析师 规格严考

关系模型

（7）自然连接是一种特殊的等值连接，它要求两个关系中进行比较的分量必须是相同的属性组，并且在结果集中将重复属性列去掉。

A	B	C
a	b	c
b	a	d
c	d	e
d	f	g

(a) 关系 R

A	C	D
a	c	d
d	f	g
b	d	g

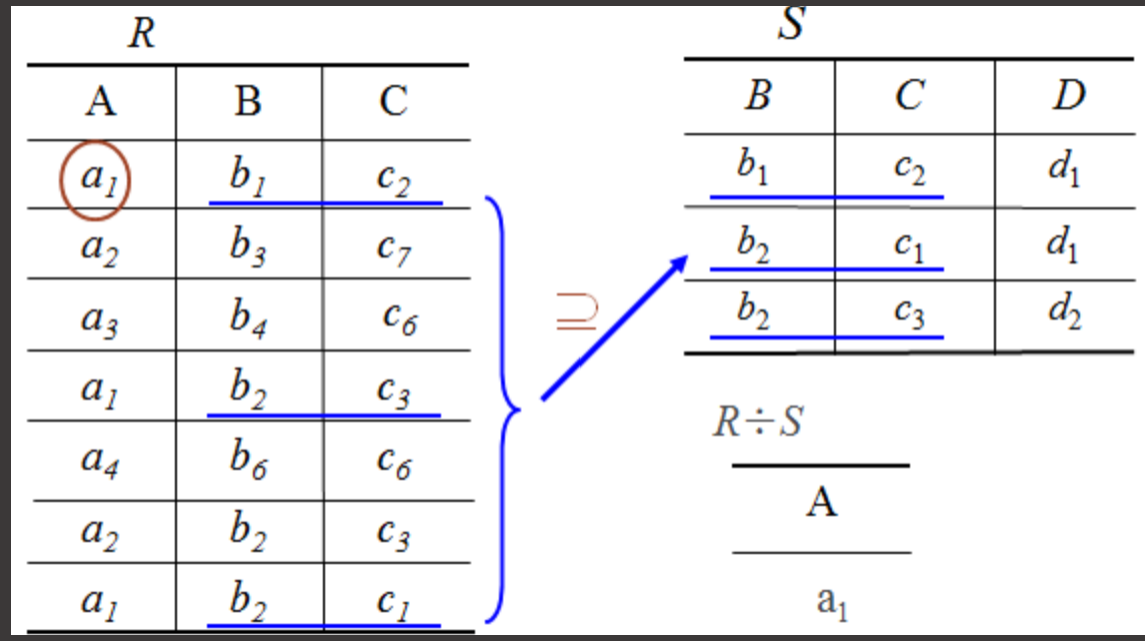
(b) 关系 S

A	B	C	D
a	b	c	d
b	a	d	g

微信公众号：规格严考；bilibili：枯燥的工程师

关系模型

（8）除。设有关系R（X，Y）与关系S（Z），Y和Z具有相同的属性个数，且对应属性出自相同域。关系R（X，Y÷S（Z）所得的商关系是关系R在属性X上投影的一个子集，该子集和S（Z）的笛卡儿积必须包含在R（X，Y）中，记为R÷S。



R

A	B	C
a_1	b_1	c_2
a_2	b_3	c_7
a_3	b_4	c_6
a_1	b_2	c_3
a_4	b_6	c_6
a_2	b_2	c_3
a_1	b_2	c_1

⊇

S

B	C	D
b_1	c_2	d_1
b_2	c_1	d_1
b_2	c_3	d_2

$R \div S$

A
a_1

表 5-1　关系 *R*

U1	U2	U3	U4
a	*b*	*c*	*d*
a	*b*	*e*	*f*
c	*a*	*c*	*d*

表 5-2　关系 *S*

U3	U4
c	*d*
e	*f*

淘宝搜索：系统分析师 规格严考

规范化理论

设有一个关系模式R（SNAME，CNAME，TNAME，TADDRESS），其属性分别表示学生姓选修的课程名、任课教师姓名和任课教师地址。仔细分析一下，会发现这个模式存在下常问题：

（1）数据冗余。如果某门课程有100个学生选修，那么在R的关系中就要出现100个元这门课程的任课教师姓名和地址也随之重复出现100次。

（2）修改异常。由于上述冗余问题，当需要修改这个教师的地址时，就要修改100个元中的地址值，否则就会出现地址值不一致的现象。

（3）插入异常。如果不知道听课学生名单，这个教师的任课情况和家庭地址就无法进入据库，否则就要在学生姓名处插入空值。

（4）删除异常。如果某门课程的任课教师要更改，那么原来任课教师的地址将随之丢失。

如果将R分解成下列两个关系模式，即R1（SNAME，CNAME）和R2（CNAME，TNAME，TADDRESS），则能消除上述的存储异常现象。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

规范化理论

1. 函数依赖与键

函数依赖：设R（U）是U上的一个关系模式，X和Y是U的子集，r为R的任一关系，如果对于r中的任意两个元组u、v，只要有u[X]=v[X]，就有u[Y]=v[Y]，则称Y依赖于X，记作X→Y。

部分函数依赖：若X→Y，但Y不完全函数依赖于X，则称Y对X部分函数依赖。

传递函数依赖：在R（U）中，如果X→Y，且Y→X不成立，Y→Z，则称Z对X传递函数依赖。

候选键：在关系模式中，如果有X→U在关系模式R（U）上成立，并且不存在X的任一真子集X’使X’→U成立，那么称X是R的一个候选键。

主键：在关系模式中，若有多个候选键，则选一个作为主键。一个关系的候选键有多个，但主键只能有一个。通常在候选键中选一个作为主键。

外键：如果两个关系拥有公共属性（集），且公共属性在一个关系中是主键，则称公共属性是另一个关系的外键。

微信公众号：规格严考；bilibili：枯燥的工程师

规范化理论

2. 范式

为了设计一个好的数据库，定义了一些好的关系模式标准，称它们为规范的关系模式或范式（NF）。分别为1NF、2NF、3NF、BCNF、4NF和5NF。实际应用中，一般只要达到3NF。

（1）第一范式（1NF）。在关系模式R中，当且仅当所有属性只包含原子值，即每个分量都是不可再分的数据项，则称R满足1NF。如表所示的教师职称情况关系就不满足1NF。

系 名 称	高级职称人数	
	教 授	副 教 授
计算机系	6	10
电子系	3	5

淘宝搜索：系统分析师 规格严考

规范化理论

（2）第二范式（2NF）。当且仅当关系模式R满足1NF，且每个非键属性（即不属于任何候选键的属性，也称为非主属性）完全依赖于候选键时，则称R满足2NF。

例如，有关系模式（A，B，C，D），其中，（A，B）→C，B→D。因此，SC的候选键为（A，B）。这样，B→D就构成了D对候选键（A，B）的部分函数依赖。因此，SC不满足2NF。若要将SC转化为2NF，可以将它拆分为SC1（A，B，C）和SC2（B，D）。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

规范化理论

（3）第三范式（3NF）。当且仅当关系模式R满足2NF，且R中消除了非键属性传递依赖于候选键时，则称R满足3NF。

例如，学生关系S（Sno，Sname，Dno，Dname，Location）的各属性分别代表学号、姓名、所在系、系名称和系地址，其数据所示。

Sno	Sname	Dno	Dname	Location
S01	张三	D01	计算机系	1 号楼
S02	李四	D01	计算机系	1 号楼
S03	王五	D01	计算机系	1 号楼
S04	赵六	D02	信息系	2 号楼
…	…	…	…	…

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

规范化理论

（4）BCNF。如果关系模式R满足1NF，且R中没有属性传递依赖于候选键时，则称R满足BCNF。BCNF需满足如下条件：①所有非主属性对每一个码都是完全函数依赖。②所有的主属性对每一个不包含它的码，也是完全函数依赖。③没有任何属性完全函数依赖于非码的任何一组属性。

假设仓库管理关系表（仓库号，存储物品号，管理员号，数量），满足一个管理员只在一个仓库工作；一个仓库可以存储多种物品，则存在如下关系：（仓库号，存储物品号）→（管理员号，数量）；（管理员号，存储物品号）→（仓库号，数量）。

所以，（仓库号，存储物品号）和（管理员号，存储物品号）都是仓库管理关系表的候选码，表中唯一非主属性为数量，它是符合第三范式的。但是，由于存在如下决定关系：

（仓库号）→（管理员号），（管理员号）→（仓库号）

即存在主属性决定主属性的情况，因此其不符合BCNF。把仓库管理关系表分解为两个关系表仓库管理表（仓库号，管理员号）和仓库表（仓库号，存储物品号，数量），这样这个数据库表是符合BCNF的，并消除了删除异常、插入异常和更新异常。

微信公众号：规格严考；bilibili：枯燥的工程师

规范化理论

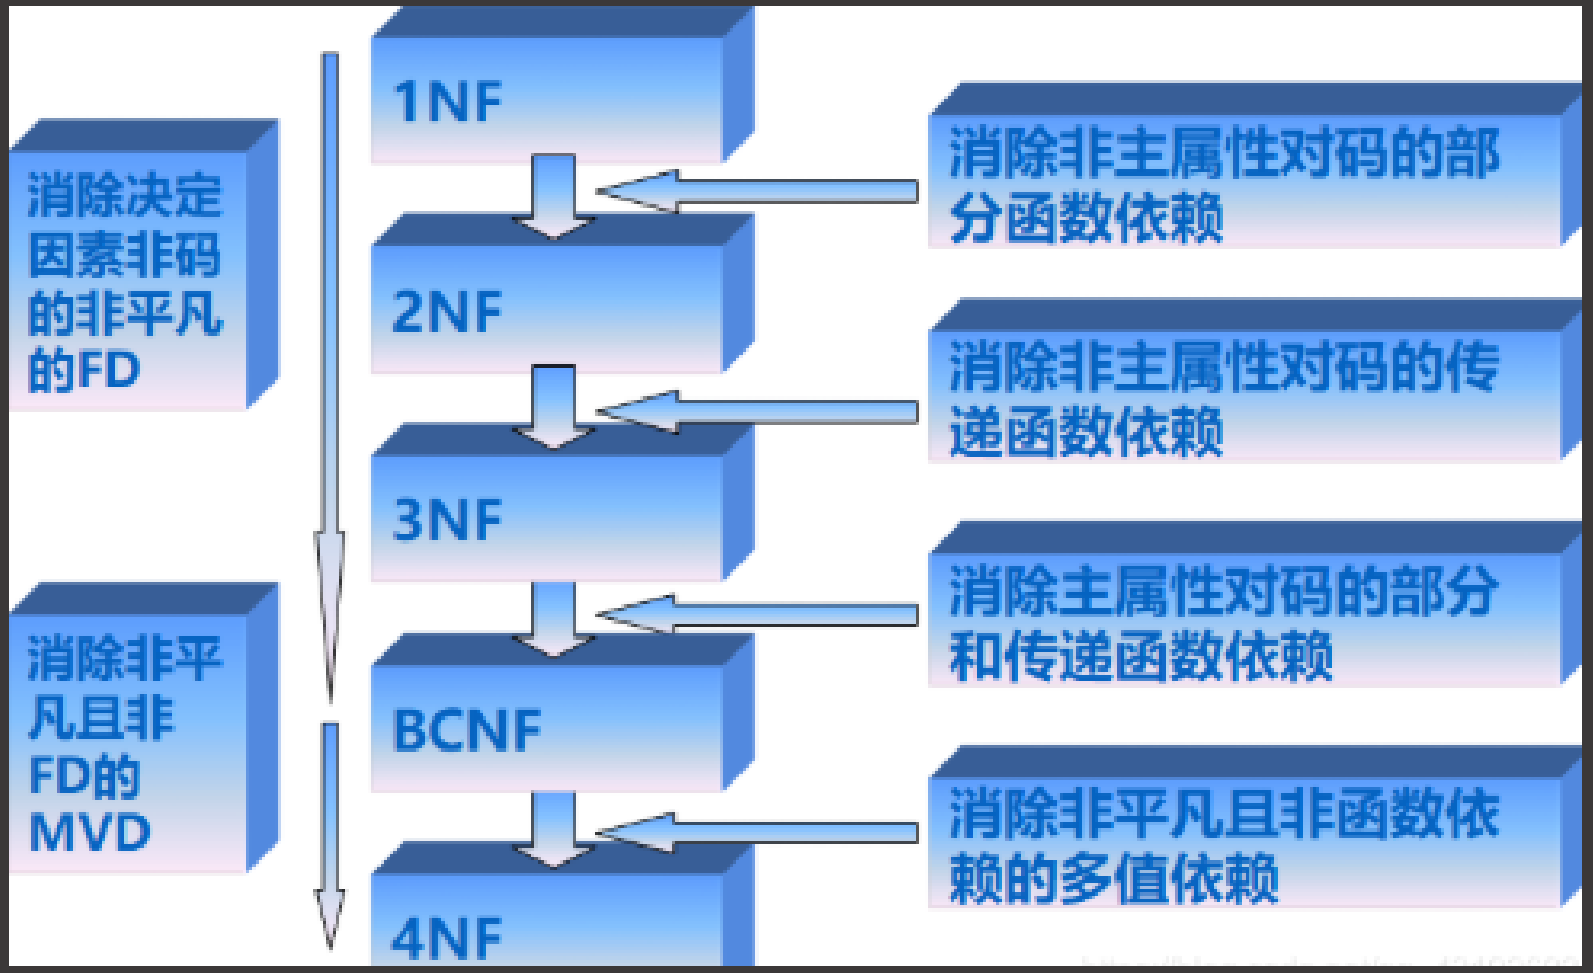
（5）第四范式（4NF）。第四范式是BCNF的推广，是针对有多值依赖的关系模型所定义的规范化形式。关系模式R（U，F）满足1NF，X，Y是U的非空子集，Z=U-X-Y也非空，若任取一组值对（x，z），都可决定一组y值，且此决定与z值无关，就称多值依赖于X，记做X→→Y。关系模式R满足1NF，若对任一多值依赖X→→Y，X必包含R的候选键，称R满足4NF。如表所示的关系QY（ypm，bm，sccj）。抛开是否规范不说，这样的登记表一目了然，但从规范化的角度来看，对ypm的一个值，不论sccj取什么值，总有一组确定的bm与之对应，所以有ypm→bm。同样，有ypm→scci。QY是全码关系（即所有的属性合在一起形成候选键）这说明QY不满足4NF。

可用分解法消除不满足4NF的多值依赖，解决办法是将QY分解为QY1（ypm，bm）和QY2（ypm，scci）。

用品名（ypm）	部门（bm）	生产厂家（sccj）
办公桌	生产经营部	美时办公用品公司
办公桌	总经理办公室	华鹤家具有限公司
办公椅	生产经营部	美时办公用品公司
办公椅	经理办公室	华鹤家具有限公司
办公椅	计划部	华鹤家具有限公司

淘宝搜索：系统分析师 规格严考

规范化理论



微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

规范化理论

3. 关系模式分解

如果某关系模式存在修改异常等问题，可通过分解该关系模式来解决。将一个关系模式分解成几个子关系模式，需要考虑的是该分解是否保持函数依赖，是否是无损联接分解。

1、判断无损联接

若交集能函数确定差集（如R1∩R2→R1-R2或R1∩R2→R2-R1），则为无损分解。

2、判断保持函数依赖

分解后的关系模式能保留原函数依赖集的所有约束。即，如果F上的每一个函数依赖都在其分解后的某一个关系上成立，则这个分解是保持依赖的（这是一个充分条件）。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.3 数据库控制功能

并发控制
数据库完整性
数据库安全
备份与恢复技术
数据库性能优化

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

并发控制

1.事务的基本概念

DBMS运行的基本工作单位是事务，事务是用户定义的一个数据库操作序列，这些操作序列要么全做，要么全不做，是一个不可分割的工作单位。事务具有以下特性：

（1）原子性（Atomicity）。事务是数据库的逻辑工作单位，事务的原子性保证事务包含的一组更新操作是原子不可分的，也就是说，这些操作是一个整体，不能部分地完成。

（2）一致性（Consistency）。一致性是指使数据库从一个一致性状态变到另一个一致性状态。例如，在转账的操作中，各账户金额必须平衡。

（3）隔离性（Isolation）。隔离性是指一个事务的执行不能被其他事务干扰。

（4）持久性（Durability）。持久性也称为永久性，是指事务一旦提交，改变就是永久性的，无论发生何种故障，都不应该对其有任何影响。

事务的原子性、一致性、隔离性和持久性通常统称为ACID特性。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

并发控制

2. 数据不一致问题

（1）丢失修改。事务A与事务B从数据库中读入同一数据并修改，事务B的提交结果破坏了事务A提交的结果，导致事务A的修改被丢失。

T1	T2
①读 A=10	
②	读 A=10
③ A=A–5，写回	
④	A=A–8，写回

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

并发控制

（2）读“脏数据”。事务A修改某一数据，并将其写回磁盘，事务B读取同一数据后，事务A由于某种原因被撤销，这时事务A已修改过的数据恢复原值，事务B读到的数据就与数据库中的数据不一致，是不正确的数据，称为“脏数据”。

T1	T2
①读 A=20 A=A+50 写回 70 ②	
③ ROLLBACK A 恢复为 20	读 A=70

微信公众号：规格严考；bilibili：枯燥的工程师

并发控制

（3）不可重复读。不可重复读是指事务A读取数据后，事务B执行了更新操作，事务A使用的仍是更新前的值，造成了数据不一致性。

T1	T2
①读 A=20 读 B=30 求和 =50	
②	读 A=20 A=A+50
	写 A=70
③读 A=70 读 B=30 求和 =100 （验算不对）	

淘宝搜索：系统分析师 规格严考

并发控制

3. 封锁协议

处理并发控制的主要方法是采用封锁技术，主要有两种封锁，分别是X封锁和S封锁。

（1）排他型封锁（X封锁）。如果事务T对数据对象A实现了X封锁，那么只允许事务T读取和修改数据A，其他事务要等事务T解除X封锁以后，才能对数据A实现任何类型的封锁。

（2）共享型封锁（S封锁）。如果事务T对数据A实现了S封锁，那么允许事务T读取数据A，但不能修改数据A，在所有S封锁解除之前，决不允许任何事务对数据A实现X封锁。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

并发控制

在多个事务并发执行的系统中，采取封锁协议来进行处理。常见的封锁协议如下：

（1）一级封锁协议。事务T在修改数据R之前必须先对其加X锁，直到事务结束才释放。可防止丢失修改，并保证事务T是可恢复的，但不能保证可重复读和不读“脏数据”

（2）二级封锁协议。一级封锁协议加上事务T在读取数据R之前先对其加S锁，读完后即可释放S锁。可防止丢失修改，还可防止读“脏数据”，但不能保证可重复读。

（3）三级封锁协议。一级封锁协议加上事务T在读取数据R之前先对其加S锁，直到事务结束才释放。三级封锁协议可防止丢失修改、读“脏数据”，且能保证可重复读。

（4）两段锁协议。所有事务必须分两个阶段对数据项加锁和解锁。其中，扩展阶段是在对任何数据进行读、写操作之前，首先要申请并获得对该数据的封锁；收缩阶段是在释放一个封锁之后，事务不能再申请和获得任何其他封锁。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

数据库完整性

触发器是在关系型DBMS中应用得比较多的一种完整性保护措施，其功能比完整性约束要强得多。一般而言，在完整性约束功能中，当系统检查出数据中有违反完整性约束条件时，仅给出必要提示以通知用户。而触发器的功能则不仅起到提示作用，还会引起系统自动进行某些操作，以消除违反完整性约束条件所引起的负面影响。

所谓触发器，其抽象的含义是一个事件的发生必然触发（或导致）另外一些事件的发生，其中，前面的事件称为触发事件，后面的事件称为结果事件。触发事件一般即为完整性约束条件的否定，而结果事件即为一组操作，用以消除触发事件所引起的不良影响。目前，数据库中的事件一般表示为数据的插入、修改、删除等操作。触发器除了有完整性保护功能外，还有安全性保护功能。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

数据库安全

数据库系统的安全性在技术上依赖于两种方式：一种是DBMS本身提供的用户身份识别、视图、使用权限控制和审计等管理措施，大型DBMS均有此功能；另一种就是靠应用程序来实现对数据库访问进行控制和管理，也就是说，数据的安全控制由应用程序里面的代码来实现。主要数据库安全措施如下表：

措　施	说　明
用户标识和鉴别	最外层的安全保护措施，可以使用用户账户、口令和随机数检验等方式
存取控制（数据授权）	对用户进行授权，包括操作类型（例如，查找、更新或删除等）和数据对象的权限
密码存储和传输	对远程终端信息用密码传输
视图的保护	通过视图的方式进行授权
审计	使用一个专用文件或数据库，自动将用户对数据库的所有操作记录下来

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

备份与恢复技术

1. 备份

按备份的实现方式，可分为物理备份与逻辑备份，物理备份又可分为冷备份与热备份。

按备份的数据量情况，可分为完全备份、增量备份与差异备份。

- 完全备份是指将整个数据库中的数据进行备份。
- 增量备份是指备份上一次备份后发生变化的数据。
- 差异备份是指备份上一次完全备份后发生变化的所有数据。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

备份与恢复技术

2. 日志文件

事务日志是针对数据库改变所做的记录，它可以记录针对数据库的任何操作，并将记录结果保存在独立的文件中。这种文件就称为日志文件。

3. 数据恢复

（1）事务故障的恢复。

（2）系统故障的恢复。

（3）介质故障与病毒破坏的恢复。

（4）有检查点的恢复技术。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

数据库性能优化

通常，对一个集中式数据库的性能进行优化，可以从硬件升级、数据库设计、索引优化策略和查询优化等方面入手。

1. 硬件升级

要提升数据库的运行速度，最直接的方式就是硬件升级，涉及的硬件包括处理器、内存、磁盘子系统和网络。

2. 数据库设计

对数据库进行设计优化，主要可以从逻辑设计和物理设计两个方面入手。

逻辑设计常用的措施如下：

（1）将常用的计算属性（例如，总计和最大值等）存储到数据库实体中。

（2）重新定义实体，以减少外部属性数据或行数据的开支。

（3）将关系进行水平或垂直分割，以提升并行访问度。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

数据库性能优化

物理设计可以遵循以下准则：

（1）与每个属性相关的数据类型应该反映数据所需的最小存储空间，特别是对于被索引的属性更是如此。

（2）将一个频繁使用的关系模式分割开，并放在两个单独的智能型磁盘控制器的数据库设备上，这样也可以提高性能。因为有多个磁头在查找，数据分离也能提高性能。

（3）将数据库中文本或图像属性的数据存放在一个单独的物理设备上，也可以提高性能。如果使用专用的智能型控制器，就能进一步提高性能。

3. 索引优化策略

索引的建立与选择对数据库性能优化具有重大意义。

4. 查询优化

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.4 数据库设计与建模

数据库设计阶段

实体联系模型

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

数据库设计阶段

5个阶段：规划、需求分析、概念设计、逻辑设计和物理设计。

1. 规划

规划阶段的主要任务是进行建立数据库的必要性及可行性分析，确定数据库系统在企业和信息系统中的地位，以及各个数据库之间的联系。

2. 需求分析

需求分析的目标是通过调查研究，了解用户的数据和处理要求，并按一定格式整理成需求说明书。

3. 概念设计

概念设计也称为概念结构设计，其任务是在需求分析阶段产生的需求说明书的基础上，按照特定的方法将它们抽象为一个不依赖于任何DBMS的数据模型，即概念模型。概念模型使设计人员的注意力能够从复杂的实现细节中解脱出来，而只集中在最重要的数据的组织结构和处理模式上。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

数据库设计阶段

4. 逻辑设计

逻辑设计的目的是将概念设计阶段设计好的E-R图转换为与选用的具体机器上的DBMS所支持的数据模型相符合的逻辑结构。

5. 物理设计

物理设计也称为物理结构设计，其任务是对给定的逻辑模型选取一个最适合应用环境的物理结构，所谓数据库的物理结构，主要是指数据库在物理设备上的存储结构和存取方法。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

实体联系模型

E-R模型也称为E-R图，它是描述概念世界、建立概念模型的实用工具。在E-R图中，主要包括以下三个要素：

（1）实体（型）。实体用矩形框表示，框内标注实体名称。

（2）属性。单值属性用椭圆形表示，并用连线与实体连接起来；如果是多值属性，在圆形虚线外面再套实线椭圆。

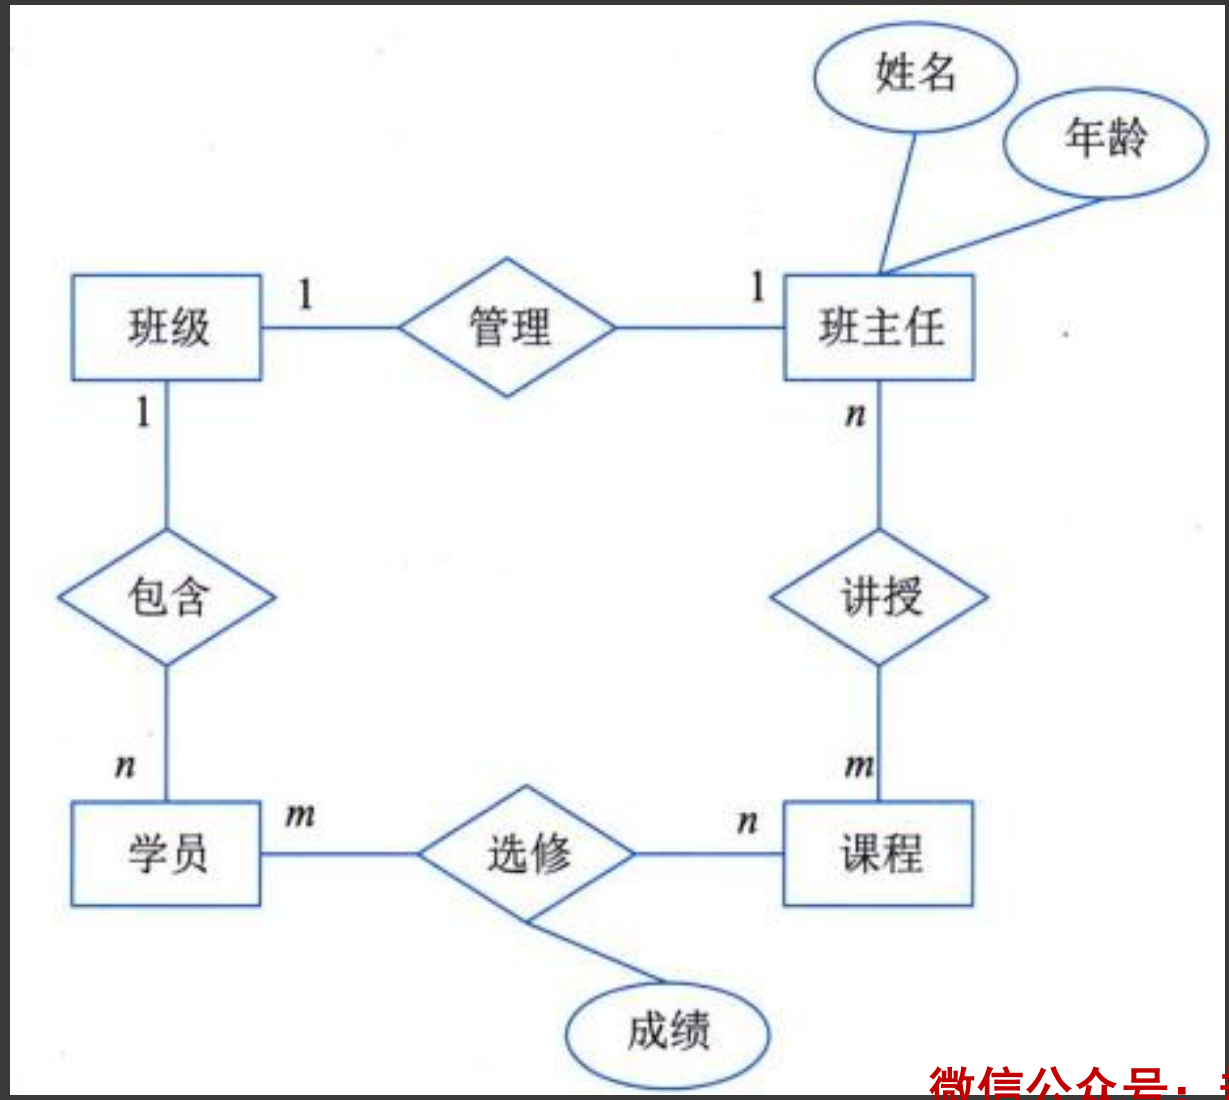
（3）实体之间的联系。实体之间的联系用菱形框表示，框内标注联系名称。

如图是某在线教育平台系统的一个E-R图。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

实体联系模型



微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

实体联系模型

1. 联系的类型

（1）一对一联系（1：1）。设A，B为两个实体集，若A中的每个实体至多和B中的一个实体有联系，B中的每个实体至多和A中的一个实体有联系，则称A对B或B对A是1：1联系。

（2）一对多联系（1：n）。如果实体集A中的每个实体可以和B中的几个实体有联系，而B中的每个实体至少和A中的一个实体有联系，则A对B属于1：n联系。

（3）多对多联系（m：n）。若实体集A中的每个实体可与B中的多个实体有联系，反过来，B中的每个实体也可以与A中的多个实体有联系，则称A对B或B对A是m：n联系。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

实体联系模型

2. E-R图的集成

首先，确定局部视图的范围：然后，识别实体及其标识，确定实体之间的联系；最后，分配实体及联系的属性。

各局部E-R图之间的冲突主要有三类：属性冲突、命名冲突和结构冲突。

（1）属性冲突。属性冲突包括属性域冲突和属性取值冲突。属性冲突理论上好解决，只要换成相同的属性就可以了，但实际上需要各部门协商，解决起来并不简单。

（2）命名冲突。命名冲突包括同名异义和异名同义。处理命名冲突通常也像处理属性冲突一样，通过讨论和协商等行政手段加以解决。

（3）结构冲突。结构冲突包括同一对象在不同应用中具有不同的抽象，以及同一实体在不同局部E-R图中所包含的属性个数和属性排列次序不完全相同。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.5 分布式数据库

分布式数据库概述

数据分片

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

分布式数据库概述

分布式数据库系统是在集中式数据库系统技术的基础上发展起来的，具有如下特点：

（1）数据独立性。

（2）集中与自治共享结合的控制结构。

（3）适当增加数据冗余度。

（4）全局的一致性、可串行性和可恢复性。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

分布式数据库概述

分布式数据库系统是在集中式数据库系统技术的基础上发展起来的，具有如下特点：

（1）数据独立性。

（2）集中与自治共享结合的控制结构。

（3）适当增加数据冗余度。

（4）全局的一致性、可串行性和可恢复性。

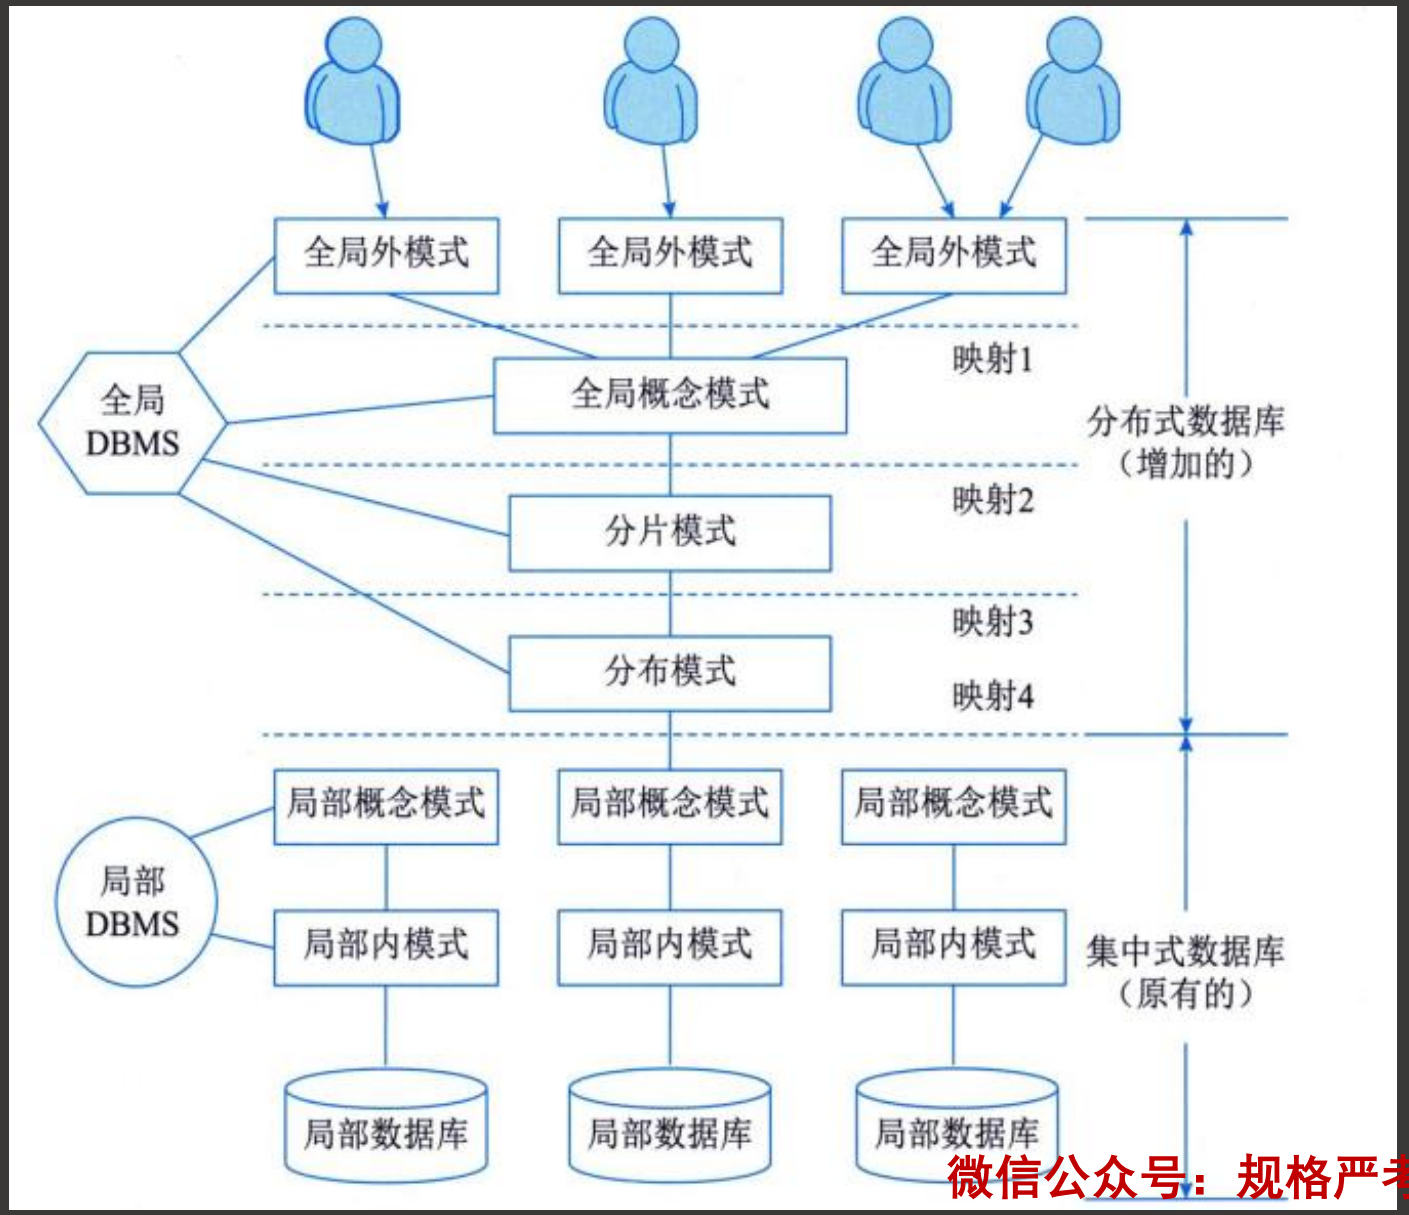
1. 分布式数据库的体系结构

在分布式数据库中，局部DBMS中的内模式和概念模式与集中数据库中是完全一致的，不同之处在于新增的全局DBMS，而整个全局DBMS可以看作是相对于局部概念模式的外模式。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

分布式数据库概述



微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

分布式数据库概述

外模式部分由一系列的分布模式、分片模式、全局概念模式和全局外模式以及多级映射组成，使用分布式数据库时，可以使用与集中式数据库相同的方式。

（1）全局外模式。全局外模式是全局应用的用户视图，直接与用户（或应用程序）交互。

（2）全局概念模式。全局概念模式定义分布式数据库中数据的整体逻辑结构，数据就如同根本没有分布一样。

（3）分片模式。在某些情况下，需要将一个关系模式分解成几个数据片。

（4）分布模式。分布式数据库的本质特性就是数据分布在不同的物理位置。分布模式的主　　要职责是定义数据片段（即分片模式的处理结果）的存放节点。

（5）局部概念模式。局部概念模式是局部数据库的概念模式，

（6）局部内模式。局部内模式是局部数据库的内模式。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

数据分片

分片的方式有多种，水平分片和垂直分片是两种基本的分片方式，混合分片和导出分片是较复杂的分片方式。

（1）水平分片。水平分片将一个全局关系中的元组分裂成多个子集，每个子集为一个片段。分片条件由关系中的属性值表示。

（2）垂直分片。垂直分片将一个全局关系按属性分裂成多个子集，应满足不相交性（关键字除外）。对于垂直分片，重构全局关系可通过连接运算实现。

（3）导出分片。导出分片又称为导出水平分片，即水平分片的条件不是本关系属性的条件，而是其他关系属性的条件。

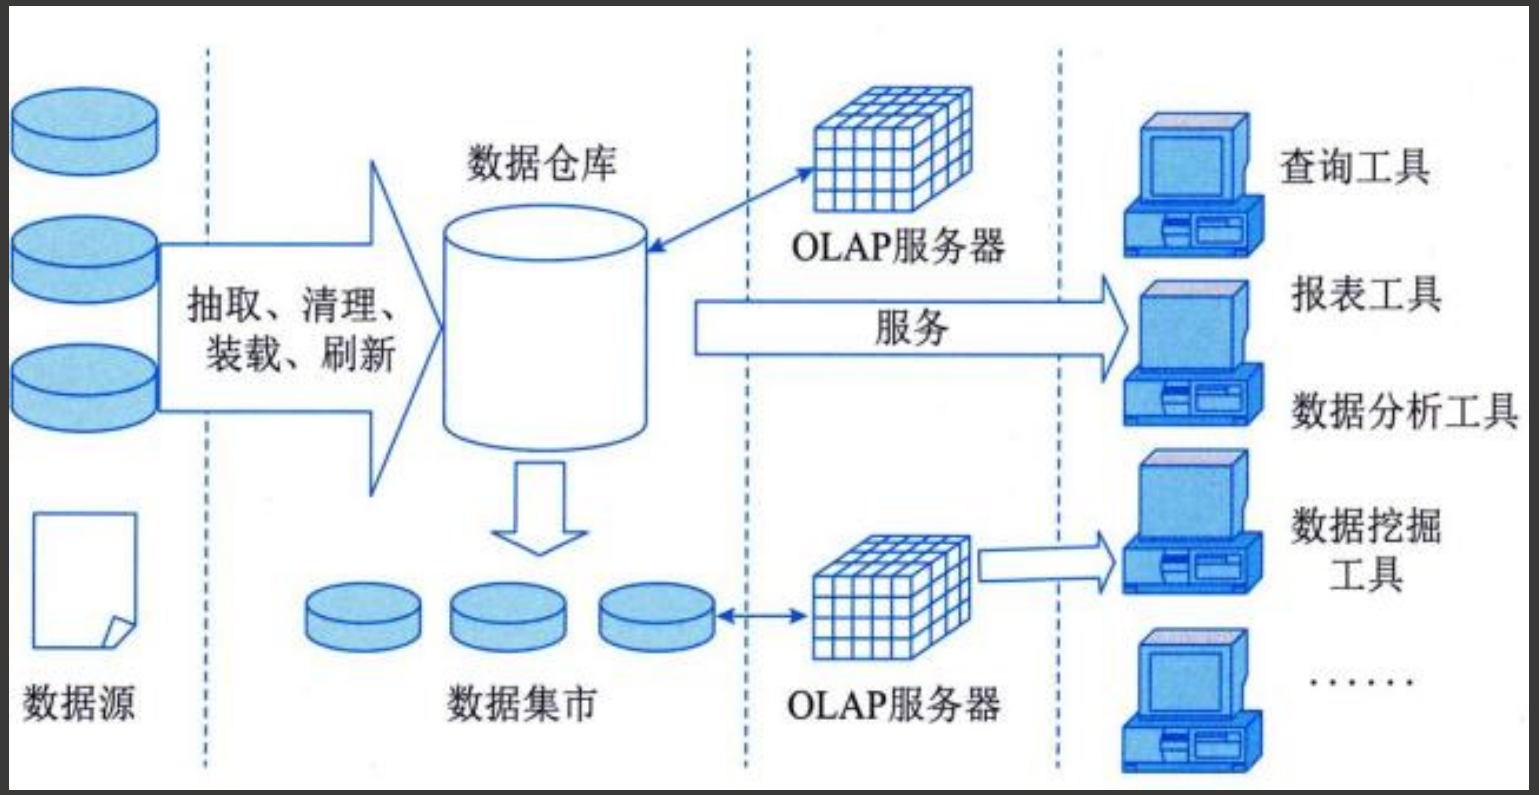
（4）混合分片。混合分片是在分片中采用水平分片和垂直分片两种形式的混合。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.6 数据仓库技术

数据仓库是一个面向主题的、集成的、相对稳定的、反映历史变化的数据集合，用于支持管理决策。数据仓库包括：



微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.6 数据仓库技术

数据仓库是一个面向主题的、集成的、相对稳定的、反映历史变化的数据集合，用于支持管理决策。数据仓库包括：

数据源是数据仓库系统的基础，是整个系统的数据源泉。

OLAP（联机分析处理）服务器对分析需要的数据进行有效集成，按多维模型予以组织，以便进行多角度、多层次的分析，并发现趋势。

前端工具主要包括各种报表工具、查询工具、数据分析工具和数据挖掘工具，以及各种基于数据仓库或数据集市的应用开发工具。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.6 数据仓库技术

1. ETL过程

针对现有各业务系统的数据，进行抽取、清理，并有效集成，按照主题进行组织，整个过程可以简称为抽取、转换和加载（ETL）过程。是OLAP和数据挖掘的基础。

2. 数据仓库的设计方法

（1）自顶向下的方法

自顶向下的方法由总体规划和设计开始，在对原始数据进行抽取、转换和迁移等处理之后，将数据输出至一个集中的数据驻留单元。然后，数据和元数据装载进入数据仓库。

（2）自底向上的方法

自底向上的方法的核心思想是从企业中最关键的部门（或功能需求）开始，先以最少的投资完成当前的需求，获得最快的回报，然后再不断扩充、不断完善。

（3）混合法

混合法是自顶向下和自底向上的方法联合使用，具有两种方法的优点，既能快速地完成数据仓库的开发与应用，还可建立具有长远价值的数据仓库方案。

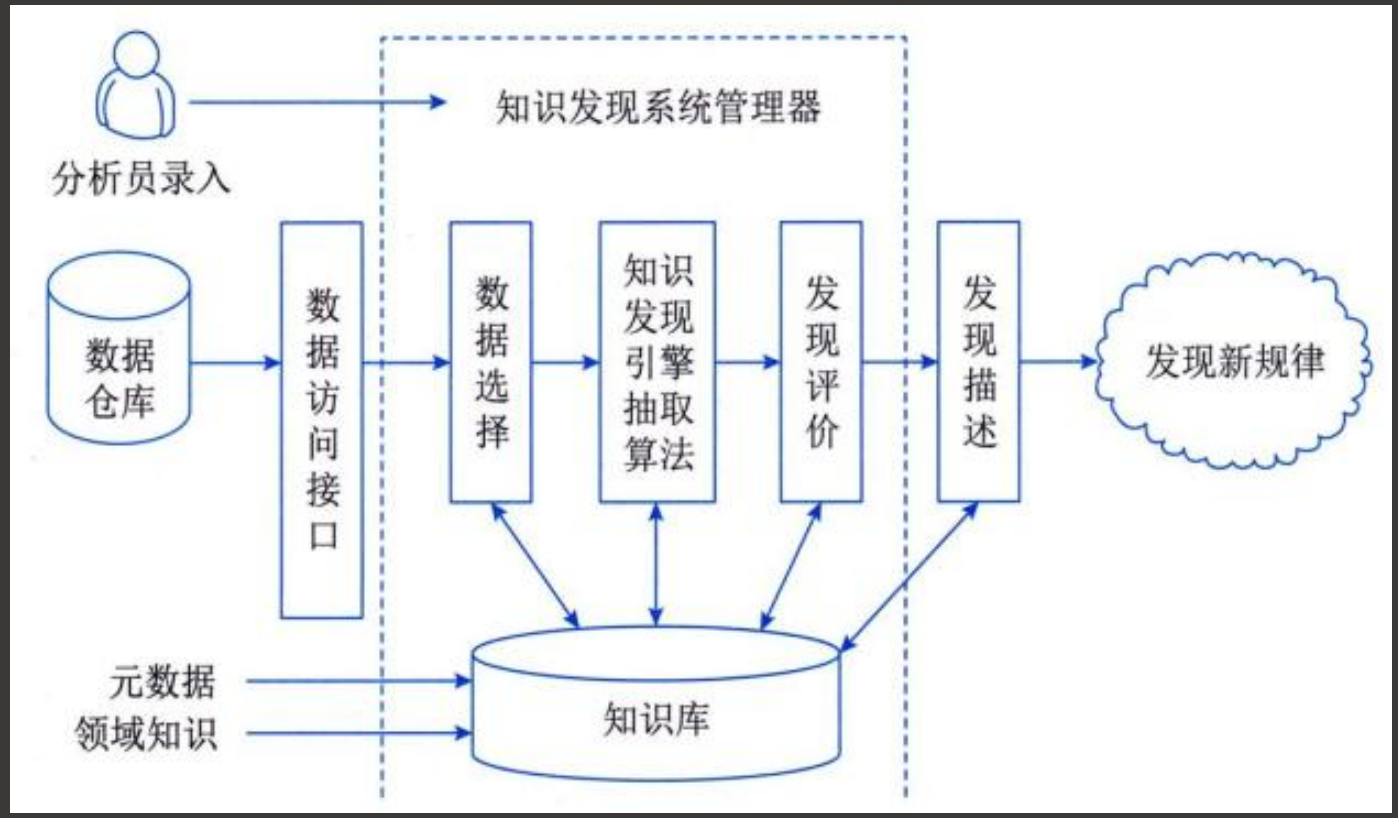
微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.7 数据挖掘

1. 数据挖掘的体系结构

如图所示为数据挖掘的体系结构，它展示了数据挖掘的流程，说明了数据挖掘是怎样找到新规律的。



微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.7 数据挖掘

2. 数据挖掘的流程

数据挖掘的流程大致如下：

（1）问题定义。最先也是最重要的要求就是熟悉背景知识，弄清用户的需求。

（2）建立数据挖掘库。要进行数据挖掘必须收集要挖掘的数据资源，一般需要将要挖掘的数据都收集到一个数据库中，而不是采用原有的数据库或数据仓库。

（3）分析数据。分析数据是对数据深入调查的过程。

（4）调整数据。尽可能对问题解决的要求做进一步明确化和量化。

（5）模型化。建立形成知识的模型。

（6）评价和解释。所得到的模型有可能是没有实际意义或没有实用价值的，也有可能不能准确反映数据的真实意义，甚至在某些情况下是与事实相反的。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.7 数据挖掘

3. 数据挖掘的常用技术

（1）决策树方法。（2）分类方法。（3）粗糙集方法。（4）神经网络。（5）关联规则。（6）概念树方法。（7）遗传算法。（8）依赖性分析。（9）公式发现。（10）统计分析方法。（11）模糊论方法。（12）可视化分析。

4. 数据挖掘的分析方法

（1）关联分析。（2）序列分析。（3）分类分析。（4）聚类分析。（5）预测方法。（6）时间序列分析。

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.8 非关系数据库

NoSQL数据库并没有统一的模型，而且是非关系型的。常见的NoSOL数据库通过存储方式划分，可分为文档存储、键值存储、列存储和图存储。

分　类	典型产品	应用场景	优　点	缺　点
文档存储	MongoDB、CouchDB	Web 应用，存储面向文档和半结构化数据	结构灵活，可以根据 value 构建索引	缺乏统一的查询语法，无事务处理能力
键值存储	Memcached、Redis	内容缓存，如会话、配置文件、参数等	扩展性好，灵活性强，大量操作时性能高	数据无结构化，通常被当成字符串或者二进制数据，通过键查询值
列存储	BigTable、HBase、Cassandra	分布式数据存储和管理	可扩展性强，查找速度快，复杂性低	功能局限，不支持事务的强一致性
图存储	Neo4j、OrientDB	社交网络、推荐系统，专注于构建系统图谱	支持复杂的图形算法	复杂性高，只能支持一定的数据规模

微信公众号：规格严考；bilibili：枯燥的工程师

淘宝搜索：系统分析师 规格严考

5.8 非关系数据库

CAP理论就是对于一个分布式系统，一致性（Consistency）、可用性（Availability）和分区容忍性（Partitiontolerance）三个特点最多只能三选二。

（1）一致性。一致性指系统在执行了某些操作后仍处在一个一致的状态，这点在分布式的系统中尤其明显。简言之，就是所有的结点在同一时刻有相同的数据。

（2）可用性。可用性指对数据的所有操作都应有成功的返回。简言之，就是任何请求不管成功或失败都有响应。

（3）分区容忍性。这一概念的前提是在网络发生故障的时候，使得原本连通的网络变成了一块一块的分区，若允许系统继续工作，那么就是分区可容忍的。

在数据库系统中，事务的ACID属性保证了数据库的一致性，然而，ACID特性对于大型的分布式系统来说，可能并不总是适合，分布式系统更多的是强调可用性和分区容忍性。由于CAP理论的存在，为了提高性能，出现了ACID的一种变种BASE，即是一个弱一致性的理论，只要求最终一致性。

微信公众号：规格严考；bilibili：枯燥的工程师

谢谢！